Проектирование нормализованной базы данных

Итоговый проект - Python для инженерии данных

Содержание

1. Введение и описание предметной области ... 3
2. Исходные данные ... 3
Проблемы денормализованных данных ... 3
3. Нормализация базы данных ... 4
4. Инфологическая модель (ER-диаграмма) ... 5
Типы связей ... 5
5. Описание сущностей и атрибутов ... 6
5.1. Таблица users -Пользователи ... 6
5.2. Таблица drivers -Курьеры ... 6
5.3. Таблица stores -Магазины ... 6
5.4. Таблица items -Товары ... 6
5.5. Таблица orders -Заказы ... 7
5.6. Таблица order_items -Позиции заказа ... 7
5.7. Таблица order_drivers -Курьеры заказа ... 7
6. Связи между сущностями (Foreign Keys) ... 8
Порядок загрузки данных ... 8
7. DDL-скрипты создания таблиц ... 9
7.1. Создание базы данных ... 9
7.2. Таблицы core-слоя ... 9
7.3. Внешние ключи ... 10
8. Аналитические витрины ... 11
8.1. mart_orders -Витрина заказов ... 11
8.2. mart_items -Витрина товаров ... 11
9. ETL-процесс загрузки данных ... 12
9.1. DAG load_core_entities (этап 1) ... 12
9.2. DAG build_datamarts (этап 2) ... 12

1. Введение и описание предметной области

Данный отчет описывает проектирование нормализованной реляционной базы данных team_3_store для сервиса доставки товаров. База данных предназначена для хранения информации о заказах, пользователях, магазинах, товарах и курьерах, а также для построения аналитических витрин с бизнес-метриками.

Основные бизнес-процессы предметной области:

- Регистрация и обслуживание пользователей (покупателей)
- Управление каталогом магазинов и товаров
- Оформление, оплата и доставка заказов
- Назначение и смена курьеров для доставки
- Отмена заказов (до и после доставки) с указанием причины
- Аналитика: расчёт оборота, выручки, прибыли и других метрик

2. Исходные данные

Исходные данные представлены в виде 34 денормализованных parquet-файлов (chunk_*.parquet), суммарным объёмом около 70 МБ. Каждая запись содержит данные одновременно о заказе, пользователе, магазине, товаре и курьере - всё в одной плоской таблице.

Проблемы денормализованных данных

- **Избыточность** - данные о пользователе, магазине и товаре дублируются в каждой строке заказа
- **Аномалии обновления** - при изменении телефона пользователя нужно обновить все его заказы
- **Аномалии вставки** - невозможно добавить новый магазин без привязки к заказу

3. Нормализация базы данных

Нормализация - это процесс организации данных в реляционной базе для минимизации избыточности и устранения аномалий вставки, обновления и удаления. Ниже описано, как данные были приведены к третьей нормальной форме (3НФ).

Исходные данные о заказах службы доставки были декомпозированы в 7 независимых таблиц, каждая из которых хранит данные только об одной сущности, без транзитивных и частичных зависимостей:

- users - клиенты (id, имя, возраст, контакты). Вынесены из заказов, чтобы данные о пользователе не дублировались в каждой строке заказа.
- drivers - курьеры (id, имя, рейтинг, транспорт). Аналогично - информация о водителе хранится в одном месте.
- stores - магазины (id, название, тип, адрес). Убраны из заказа, связь через внешний ключ.
- items - товары (id, название, цена, категория). Каталог товаров отделён от заказов -цена и описание не повторяются.
- orders - заказы (id, user_id -> users, store_id -> stores, дата, статус, стоимость доставки). Содержит только атрибуты самого заказа, все связанные сущности -по FK.
- order_items - связь заказ–товар (order_id -> orders, item_id -> items, количество). Разрешает связь «многие ко многим» между заказами и товарами. Без этой таблицы пришлось бы хранить списки товаров в одном поле или дублировать строки заказа.
- order_drivers - связь заказ–курьер (order_id -> orders, driver_id -> drivers). Разрешает связь «многие ко многим» - один заказ может обслуживаться несколькими курьерами, и один курьер везёт много заказов.

4. Инфологическая модель (ER-диаграмма)

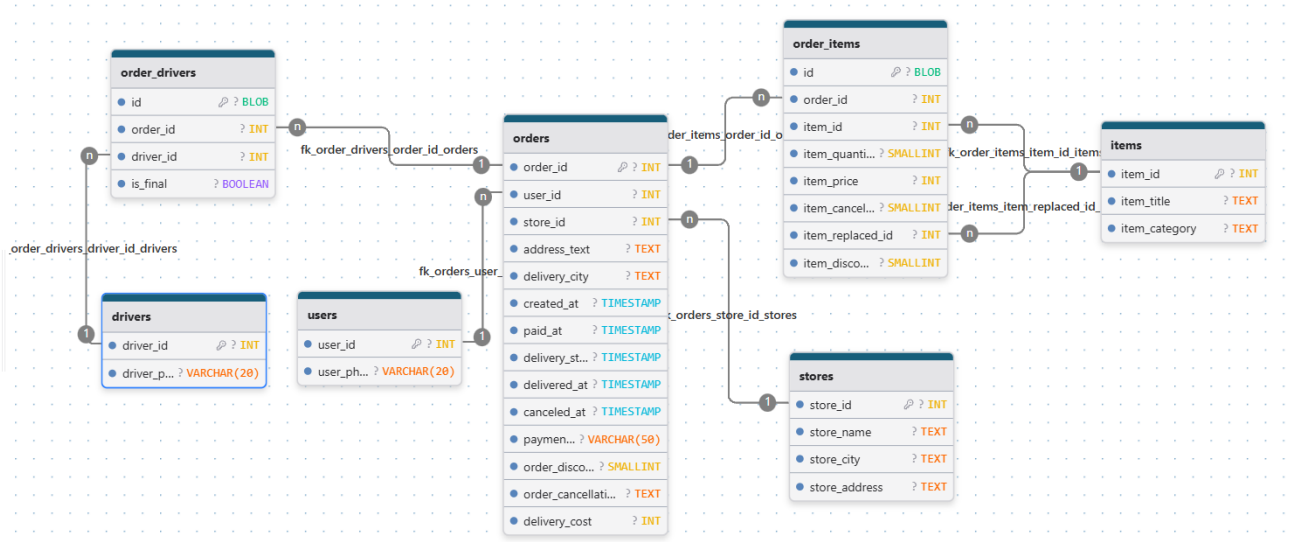

Типы связей

Связь	Тип	Описание
users -> orders	1 : N	Один пользователь может иметь много заказов
stores -> orders	1 : N	Один магазин может обработать много заказов
orders -> order_items	1 : N	Один заказ содержит много позиций товаров
orders -> order_drivers	1 : N	Один заказ может быть назначен нескольким курьерам
items -> order_items	1 : N	Один товар может быть в разных заказах
items -> order_items (replaced)	1 : N	Товар-замена для отменённой позиции
drivers -> order_drivers	1 : N	Один курьер доставляет много заказов

->

5. Описание сущностей и атрибутов

5.1. Таблица users - Пользователи

Справочник пользователей (покупателей) сервиса доставки.

Атрибут	Тип	Ограничения	Описание
user_id	INT	PK	Уникальный идентификатор пользователя
user_phone	VARCHAR(20)	-	Телефон пользователя

5.2. Таблица drivers - Курьеры

Справочник курьеров, осуществляющих доставку.

Атрибут	Тип	Ограничения	Описание
driver_id	INT	PK	Уникальный идентификатор курьера
driver_phone	VARCHAR(20)	-	Телефон курьера

5.3. Таблица stores - Магазины

Справочник магазинов-партнёров сервиса доставки.

Атрибут	Тип	Ограничения	Описание
store_id	INT	PK	Уникальный идентификатор магазина
store_name	TEXT	-	Название магазина (извлечено из адреса)
store_city	TEXT	-	Город расположения магазина
store_address	TEXT	-	Полный адрес магазина

5.4. Таблица items - Товары

Каталог товаров, доступных для заказа.

Атрибут	Тип	Ограничения	Описание
item_id	INT	PK	Уникальный идентификатор товара
item_title	TEXT	-	Название товара
item_category	TEXT	-	Категория товара

5.5. Таблица orders - Заказы

Центральная таблица, содержащая информацию о заказах.

Атрибут	Тип	Ограничения	Описание
order_id	INT	PK	Уникальный идентификатор заказа
user_id	INT	FK -> users	Покупатель, оформивший заказ
store_id	INT	FK -> stores	Магазин, из которого доставляется заказ
address_text	TEXT	-	Полный адрес доставки
delivery_city	TEXT	-	Город доставки (извлечён из адреса)
created_at	TIMESTAMPTZ	-	Дата и время создания заказа
paid_at	TIMESTAMPTZ	-	Дата и время оплаты
delivery_started_at	TIMESTAMPTZ	-	Дата и время начала доставки
delivered_at	TIMESTAMPTZ	-	Дата и время завершения доставки
canceled_at	TIMESTAMPTZ	-	Дата и время отмены заказа
payment_type	VARCHAR(50)	-	Тип оплаты
order_discount	SMALLINT	DEFAULT 0	Скидка на заказ
order_cancellation_reason	TEXT	-	Причина отмены заказа
delivery_cost	INT	DEFAULT 0	Стоимость доставки

5.6. Таблица order_items - Позиции заказа

Таблица-связка между заказами и товарами (связь многие-ко-многим). Хранит детализацию каждой товарной позиции в заказе.

Атрибут	Тип	Ограничения	Описание
id	TEXT	PK	Суррогатный ключ (order_id_item_id_N)
order_id	INT	FK -> orders	Идентификатор заказа
item_id	INT	FK -> items	Идентификатор товара
item_quantity	SMALLINT	DEFAULT 0	Количество заказанного товара
item_price	INT	DEFAULT 0	Цена за единицу товара
item_canceled_quantity	SMALLINT	DEFAULT 0	Количество отменённых единиц
item_replaced_id	INT	FK -> items	ID товара-замены (если была замена)
item_discount	SMALLINT	DEFAULT 0	Скидка на позицию

5.7. Таблица order_drivers - Курьеры заказа

Таблица-связка между заказами и курьерами. Один заказ может быть передан нескольким курьерам (например, при смене курьера).

Атрибут	Тип	Ограничения	Описание
id	TEXT	PK	Суррогатный ключ (order_id_driver_id_N)
order_id	INT	FK -> orders	Идентификатор заказа
driver_id	INT	FK -> drivers	Идентификатор курьера
is_final	BOOLEAN	DEFAULT TRUE	Является ли курьер финальным

6. Связи между сущностями (Foreign Keys)

Целостность данных обеспечивается внешними ключами (FOREIGN KEY) с политикой ON UPDATE NO ACTION ON DELETE NO ACTION - запрещается удаление или изменение записей, на которые ссылаются другие таблицы.

Таблица	FK-атрибут	Ссылается на	Описание
orders	user_id	users(user_id)	Покупатель заказа
orders	store_id	stores(store_id)	Магазин заказа
order_items	order_id	orders(order_id)	Заказ позиции
order_items	item_id	items(item_id)	Товар в позиции
order_items	item_replaced_id	items(item_id)	Товар-замена
order_drivers	order_id	orders(order_id)	Заказ курьера
order_drivers	driver_id	drivers(driver_id)	Курьер заказа

Порядок загрузки данных

Для корректной работы внешних ключей данные загружаются в следующем порядке:

- 1. Справочники: users, drivers, stores, items (независимые таблицы)
- 2. Заказы: orders (зависит от users и stores)
- 3. Детализация: order_items (зависит от orders и items)
- 4. Назначения: order_drivers (зависит от orders и drivers)

7. DDL-скрипты создания таблиц

Ниже приведены DDL-скрипты для создания всех таблиц базы данных **team_3_store**.

7.1. Создание базы данных

```
CREATE DATABASE team_3_store;
\c team_3_store;
```

7.2. Таблицы core-слоя

```
CREATE TABLE IF NOT EXISTS "users" (
    "user_id"    INT,
    "user_phone" VARCHAR(20),
    PRIMARY KEY("user_id")
);

CREATE TABLE IF NOT EXISTS "drivers" (
    "driver_id"    INT,
    "driver_phone" VARCHAR(20),
    PRIMARY KEY("driver_id")
);

CREATE TABLE IF NOT EXISTS "stores" (
    "store_id"      INT,
    "store_name"    TEXT,
    "store_city"    TEXT,
    "store_address" TEXT,
    PRIMARY KEY("store_id")
);

CREATE TABLE IF NOT EXISTS "items" (
    "item_id"       INT,
    "item_title"    TEXT,
    "item_category" TEXT,
    PRIMARY KEY("item_id")
);

CREATE TABLE IF NOT EXISTS "orders" (
    "order_id"                  INT,
    "user_id"                   INT,
    "store_id"                  INT,
    "address_text"              TEXT,
    "delivery_city"             TEXT,
    "created_at"                TIMESTAMPTZ,
    "paid_at"                   TIMESTAMPTZ,
    "delivery_started_at"       TIMESTAMPTZ,
    "delivered_at"              TIMESTAMPTZ,
    "canceled_at"               TIMESTAMPTZ,
    "payment_type"              VARCHAR(50),
    "order_discount"            SMALLINT DEFAULT 0,
    "order_cancellation_reason" TEXT,
    "delivery_cost"             INT DEFAULT 0,
    PRIMARY KEY("order_id")
);

CREATE TABLE IF NOT EXISTS "order_items" (
    "id"                     TEXT,
    "order_id"               INT,
    "item_id"                INT,
    "item_quantity"          SMALLINT DEFAULT 0,
    "item_price"             INT DEFAULT 0,
    "item_canceled_quantity" SMALLINT DEFAULT 0,
    "item_replaced_id"       INT,
    "item_discount"          SMALLINT DEFAULT 0,
    PRIMARY KEY("id")
);

CREATE TABLE IF NOT EXISTS "order_drivers" (
    "id"        TEXT,
    "order_id"  INT,
    "driver_id" INT,
    "is_final"  BOOLEAN DEFAULT TRUE,
    PRIMARY KEY("id")
);
```

7.3. Внешние ключи

```
ALTER TABLE "orders" ADD FOREIGN KEY("user_id") REFERENCES "users"("user_id") ON UPDATE NO
ACTION ON DELETE NO ACTION;
ALTER TABLE "orders" ADD FOREIGN KEY("store_id") REFERENCES "stores"("store_id") ON UPDATE NO
ACTION ON DELETE NO ACTION;
ALTER TABLE "order_items" ADD FOREIGN KEY("order_id") REFERENCES "orders"("order_id") ON
UPDATE NO ACTION ON DELETE NO ACTION;
ALTER TABLE "order_items" ADD FOREIGN KEY("item_id") REFERENCES "items"("item_id") ON UPDATE
NO ACTION ON DELETE NO ACTION;
ALTER TABLE "order_items" ADD FOREIGN KEY("item_replaced_id") REFERENCES "items"("item_id") ON
UPDATE NO ACTION ON DELETE NO ACTION;
ALTER TABLE "order_drivers" ADD FOREIGN KEY("order_id") REFERENCES "orders"("order_id") ON
UPDATE NO ACTION ON DELETE NO ACTION;
ALTER TABLE "order_drivers" ADD FOREIGN KEY("driver_id") REFERENCES "drivers"("driver_id") ON
UPDATE NO ACTION ON DELETE NO ACTION;
```

8. Аналитические витрины

На основе core-таблиц строятся две аналитические витрины, агрегирующие данные по дате, городу и магазину.

8.1. mart_orders -Витрина заказов

Агрегированные метрики заказов в разрезе дата / город / магазин.

Метрика	Тип	Формула / Описание
turnover	NUMERIC	SUM(qty * price - discount) -оборот
revenue	NUMERIC	SUM((qty - canceled_qty) * price - discount) -выручка
profit	NUMERIC	revenue - SUM(delivery_cost) -прибыль
created_orders_cnt	INT	COUNT(DISTINCT order_id) -создано заказов
delivered_orders_cnt	INT	Количество доставленных заказов
canceled_orders_cnt	INT	Количество отменённых заказов
cancel_after_delivery_cnt	INT	Отмены после доставки
service_error_cancel_cnt	INT	Отмены по причине ошибки сервиса
buyers_cnt	INT	COUNT(DISTINCT user_id) -уникальные покупатели
avg_check	NUMERIC	revenue / кол-во заказов -средний чек
orders_per_buyer	NUMERIC	Заказов на покупателя
revenue_per_buyer	NUMERIC	Выручка на покупателя
driver_changes_cnt	INT	Количество смен курьера
active_drivers_cnt	INT	Количество активных курьеров

8.2. mart_items -Витрина товаров

Агрегированные метрики товаров в разрезе дата / город / магазин / товар.

Метрика	Тип	Формула / Описание
item_turnover	NUMERIC	SUM(qty * price - discount) -оборот по товару
ordered_qty	INT	SUM(item_quantity) -заказано единиц
canceled_qty	INT	SUM(item_canceled_quantity) -отменено единиц
orders_with_item_cnt	INT	В скольких заказах присутствует товар
orders_with_item_cancel_cnt	INT	В скольких заказах отменён товар

9. ETL-процесс загрузки данных

ETL-процесс реализован в виде двух DAG-ов Apache Airflow:

9.1. DAG load_core_entities (этап 1)

Загрузка данных из parquet-файлов в нормализованные core-таблицы PostgreSQL.

- **Идемпотентность:** перед загрузкой выполняется TRUNCATE ... CASCADE всех core-таблиц
- **Дедупликация:** удаление дубликатов по первичному ключу каждой сущности
- **Парсинг адресов:** извлечение store_name, store_city из store_address и delivery_city из address_text
- **Суррогатные ключи:** генерация текстовых ID для order_items и order_drivers (order_id_item_id_N)

9.2. DAG build_datamarts (этап 2)

Построение аналитических витрин на основе core-таблиц.

- Создание таблиц витрин (CREATE TABLE IF NOT EXISTS)
- Очистка витрин (TRUNCATE)
- Вставка агрегированных данных с использованием CTE и оконных функций